Ethics_of_AI_ECE_DATA_IA

ING5 · ECE 2026-2027

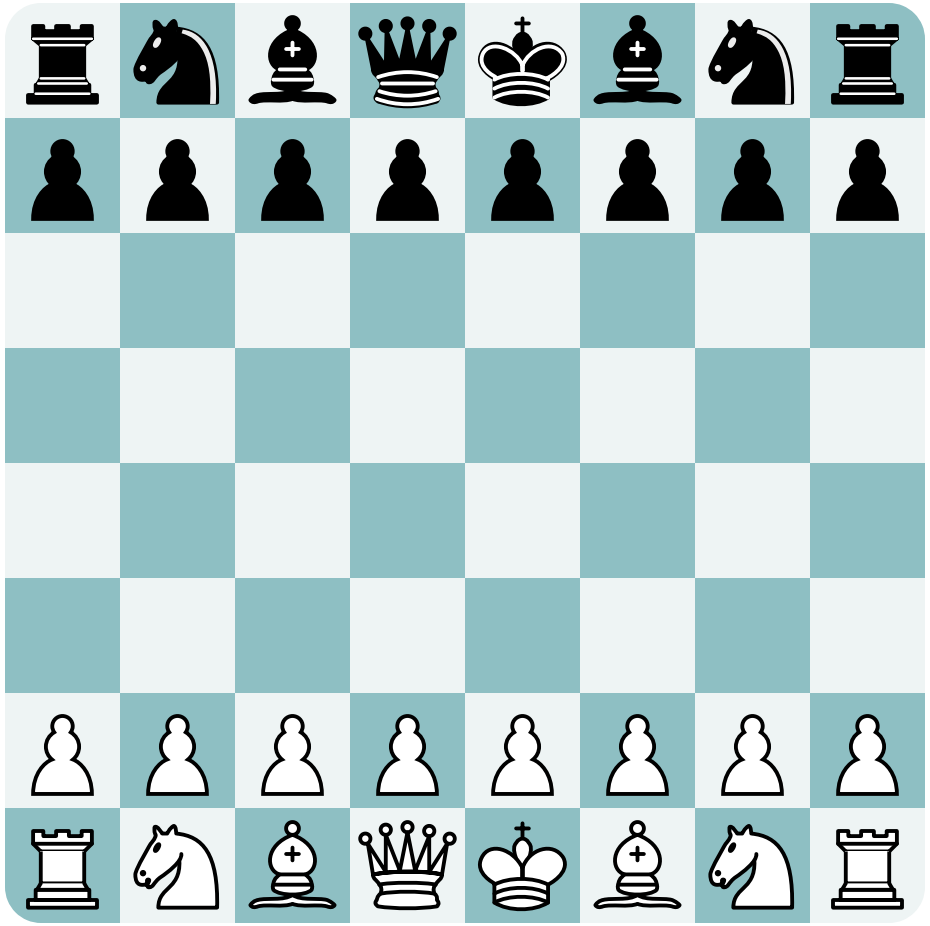
Deviner l'Elo d'un joueur d'échecs en une partie, sans préjugé de nationalité

Peut-on estimer le niveau d'un joueur à partir d'une seule partie, et le faire équitablement, quel que soit son pays ?

Thibault Rabbé · **Maël Vaudin** · **Hugo Rivière**

github.com/ChaseX9/Project-Ethics-of-IA

Les échecs en 20 secondes

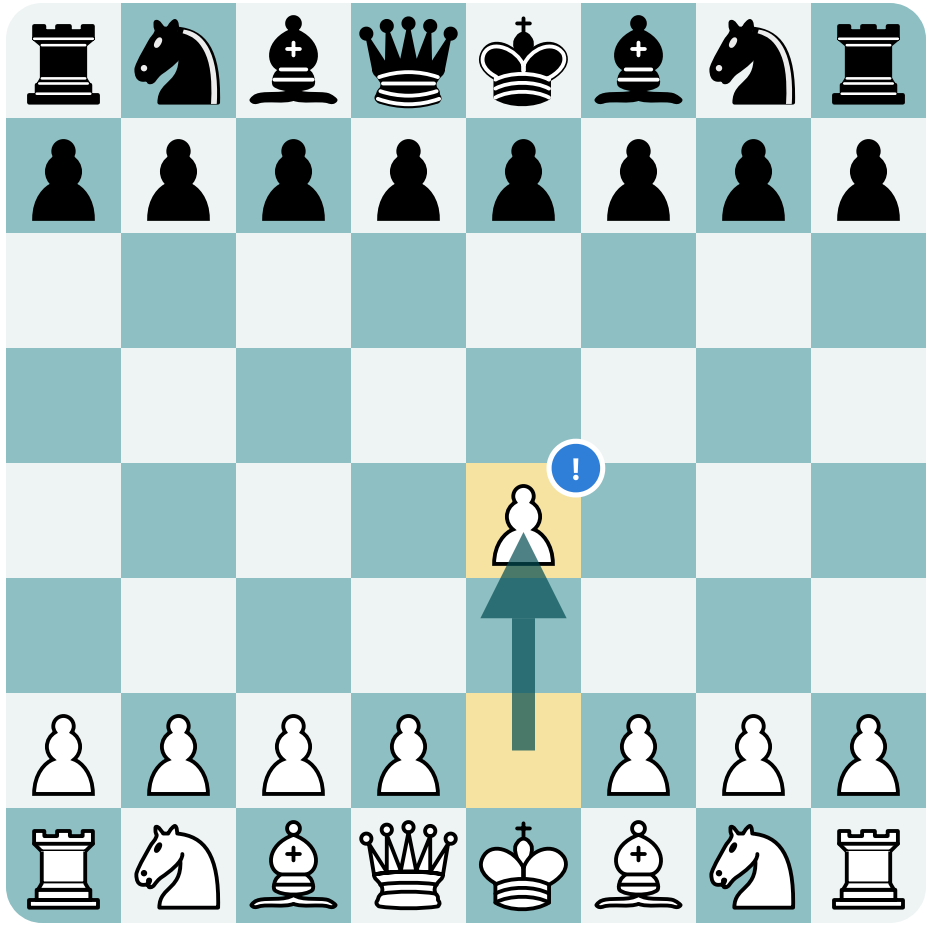


Blancs contre noirs
chacun son tour, les blancs commencent

6 sortes de pièces
pion, cavalier, fou, tour, dame, roi

Le but : mettre le roi adverse
échec et mat

Une partie en 4 coups : le coup du berger



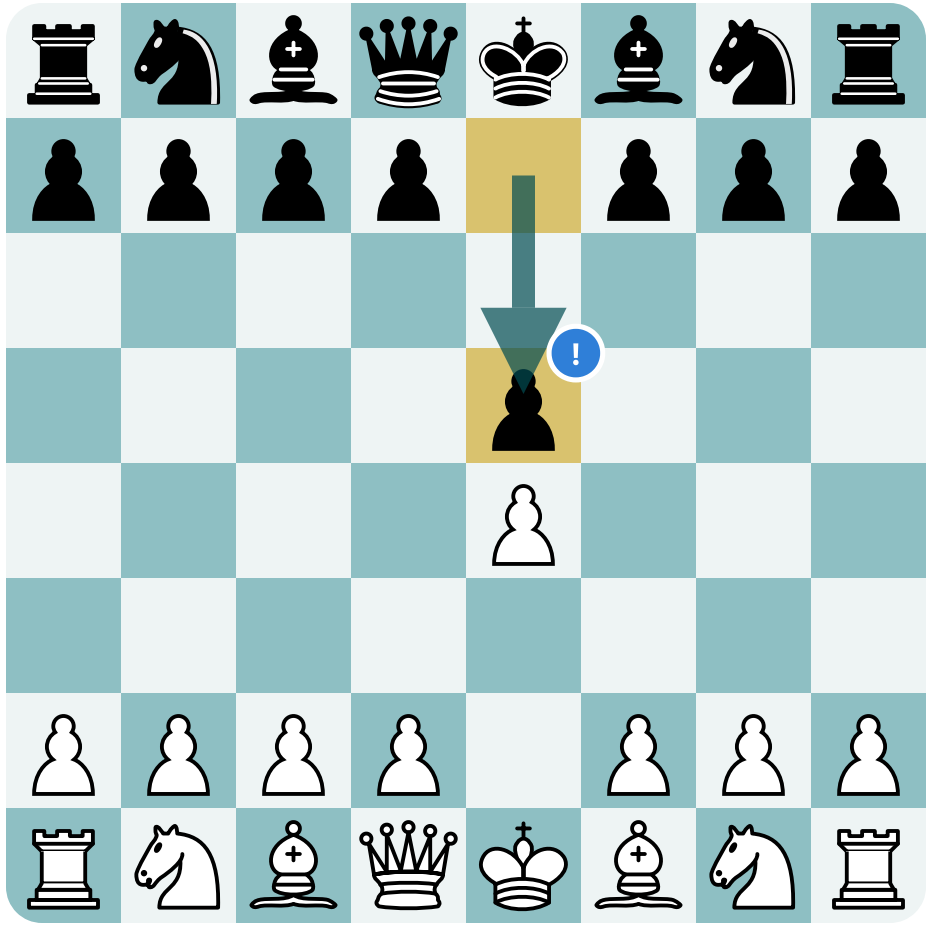
1. e4 ! 1... e5 2. Fc4 2... Cc6 3. Dh5 3... Cf6 4. Dxf7#

1. e4

Stockfish : bon coup

Les blancs avancent un pion au centre.

Une partie en 4 coups : le coup du berger



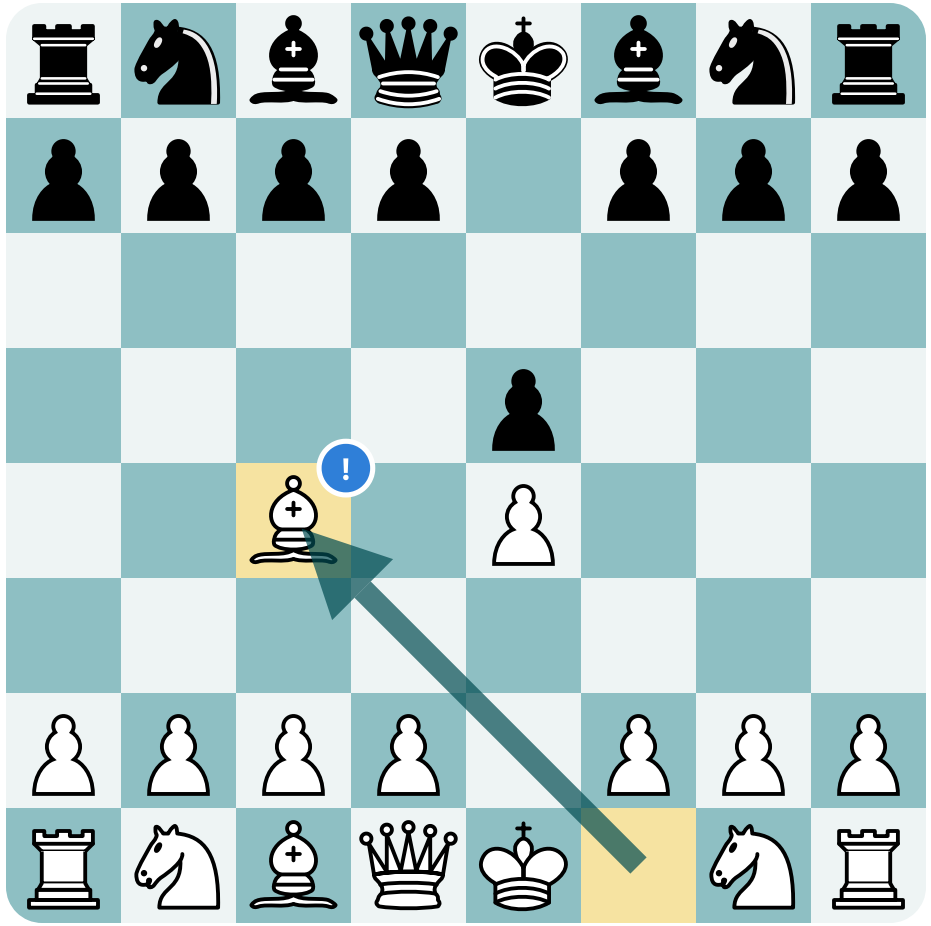
1. e4 ! **1... e5 !** 2. Fc4 2... Cc6 3. Dh5 3... Cf6 4. Dxf7#

1... e5

Stockfish : bon coup

Les noirs répondent de la même façon.

Une partie en 4 coups : le coup du berger



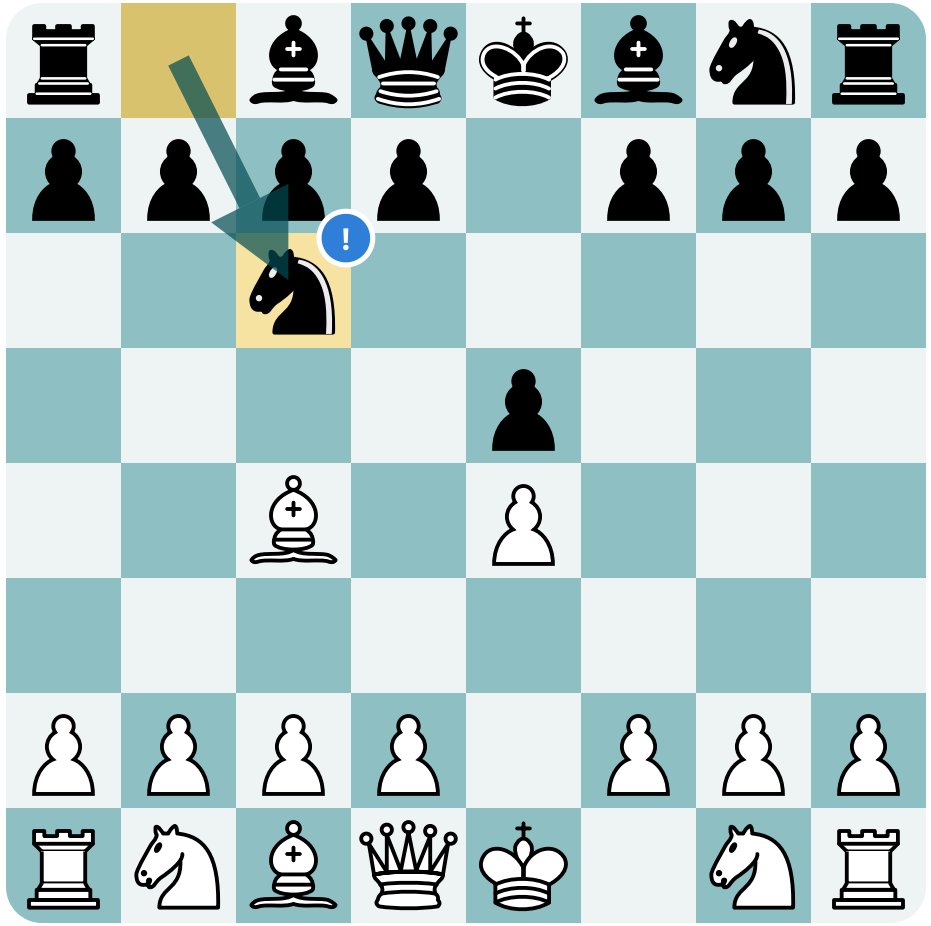
1. e4 ! 1... e5 ! **2. Fc4 !** 2... Cc6 3. Dh5 3... Cf6 4. Dxf7#

2. Fc4

Stockfish : bon coup

Le fou vise la case f7, le point faible des noirs.

Une partie en 4 coups : le coup du berger



1. e4 ! 1... e5 ! 2. Fc4 ! **2... Cc6 !**

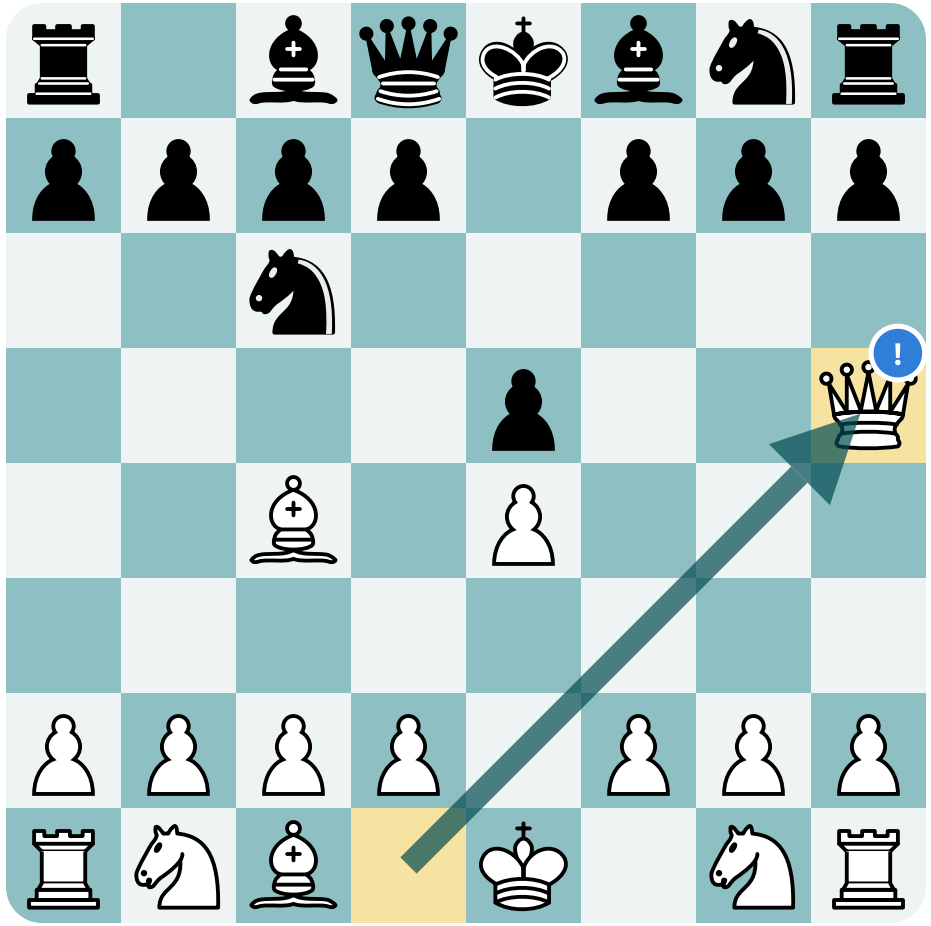
3. Dh5 3... Cf6 4. Dxf7#

2... Cc6

Stockfish : bon coup

Les noirs sortent un cavalier.

Une partie en 4 coups : le coup du berger



1. e4 ! 1... e5 ! 2. Fc4 ! 2... Cc6 !

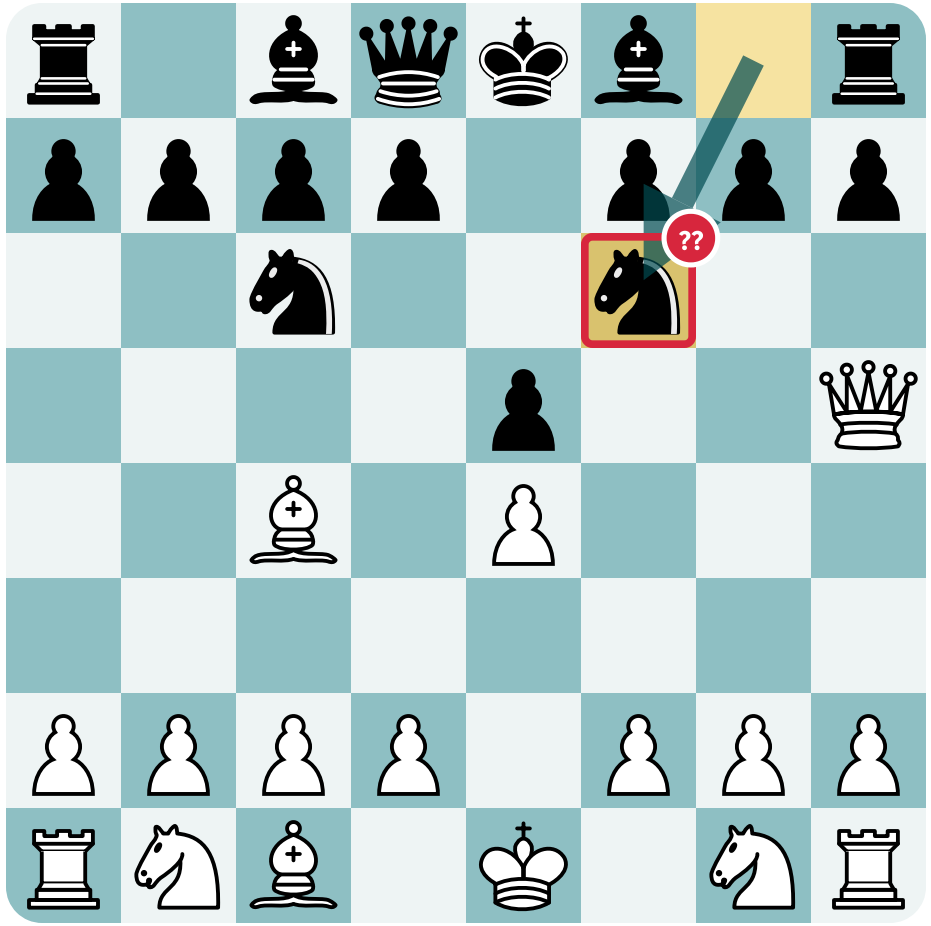
3. Dh5 ! 3... Cf6 4. Dxf7#

3. Dh5

Stockfish : bon coup

La dame vise f7 elle aussi : la menace est double.

Une partie en 4 coups : le coup du berger



1. e4 ! 1... e5 ! 2. Fc4 ! 2... Cc6 !

3. Dh5 ! **3... Cf6 ??** 4. Dxf7#

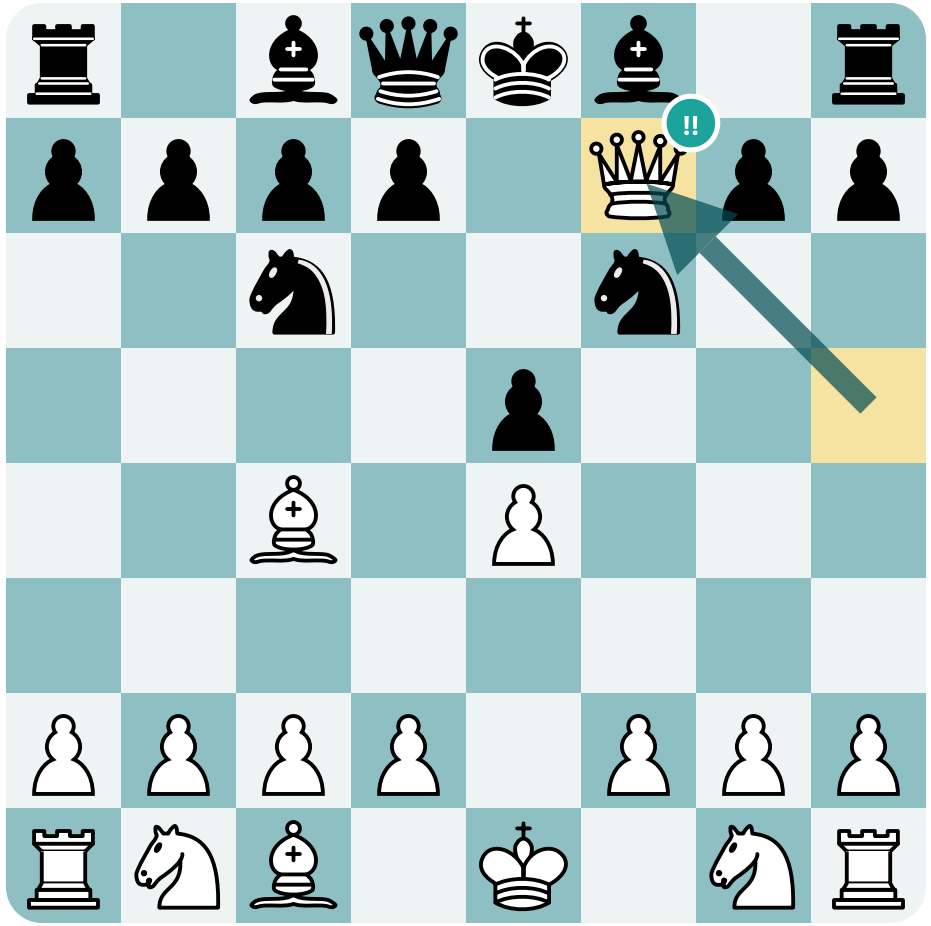
??

3... Cf6

Stockfish : gaffe

Les noirs attaquent la dame... et oublient de défendre f7.

Une partie en 4 coups : le coup du berger



1. e4 ! 1... e5 ! 2. Fc4 ! 2... Cc6 !

3. Dh5 ! 3... Cf6 ?? **4. Dxf7# !!**

!!

4. Dxf7#

Stockfish : seul coup gagnant

La dame prend f7 : échec et mat en 4 coups.

Comment juger le niveau d'un joueur ?

?? Compter ses gaffes

les coups qui changent l'issue de la partie

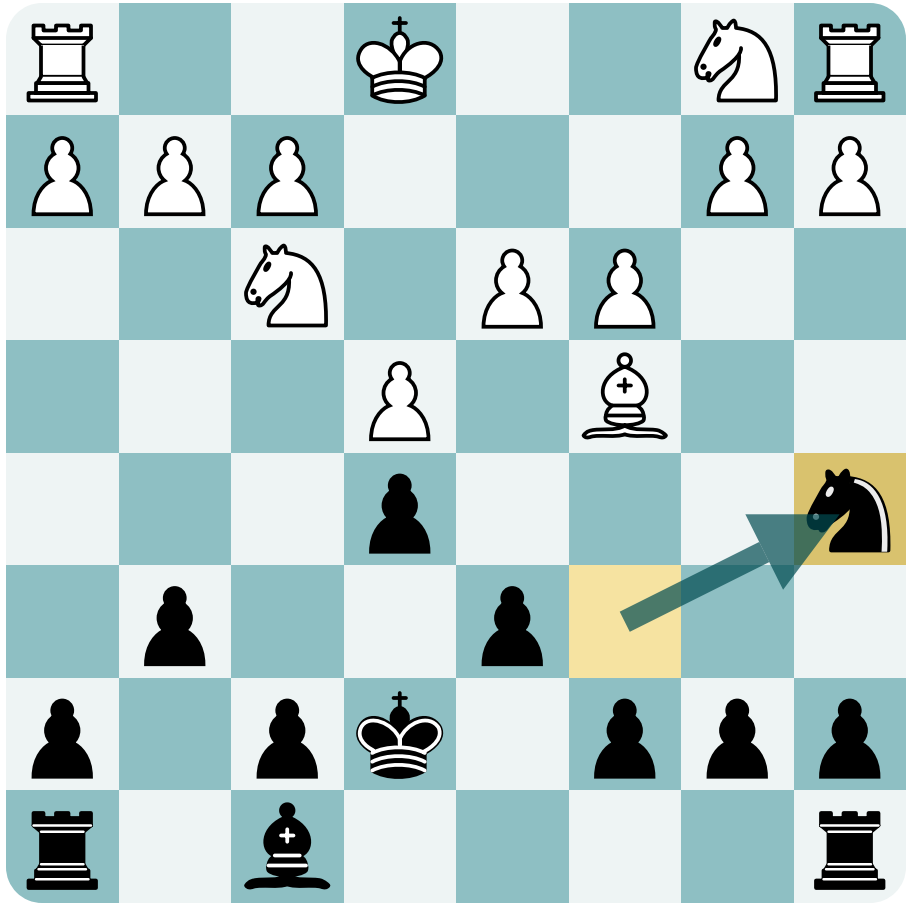
↘ Mesurer ses pertes

ce qu'il perd à chaque coup, en centièmes de pion (1 pion = 100) : l'**ACPL**



C'est exactement ce que fait Stockfish, le moteur d'échecs

À votre avis, quel est l'Elo de ce joueur ?



Le joueur a les	**noirs**
Ouverture	**1. e4 e5 2. Dh5**
Défaite	**échec et mat, 67 coups**
Erreurs	**8 gaffes · 2 erreurs**
ACPL	**117,5**

Elo = ?

Le problème : une IA risque de juger un joueur sur sa nationalité, et ce n'est pas normal

Les modèles de langage apprennent sur des milliards de textes du web, qui contiennent aussi des **clichés sur les pays**.



même partie

1 500

≠



même partie

1 400

Exemple fictif : si l'IA donne un Elo différent pour la **même partie**, c'est le pays qui décide, pas le jeu.

Même partie, même Elo prédit, quel que soit le pays

Notre cas d'usage : placer un joueur sans classement dans un tournoi, sur son seul jeu



Joueur sans classement

1 partie de placement

IA : Elo estimé

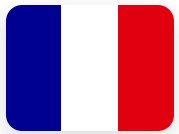
Sa poule de niveau

Mal placé, un joueur affronte des adversaires bien trop forts, ou bien trop faibles

Nous avons construit notre propre dataset : 4 200 vraies parties, 5 pays, 7 niveaux

Chess.com API publique

- **Départ** 10 joueurs par pays
- **Boule de neige** on visite leurs adversaires
- **Filtres** comptes fermés et tricheurs exclus
- **Quotas** mêmes niveaux dans chaque pays


France


Inde


États-Unis


Brésil


Allemagne

4 200

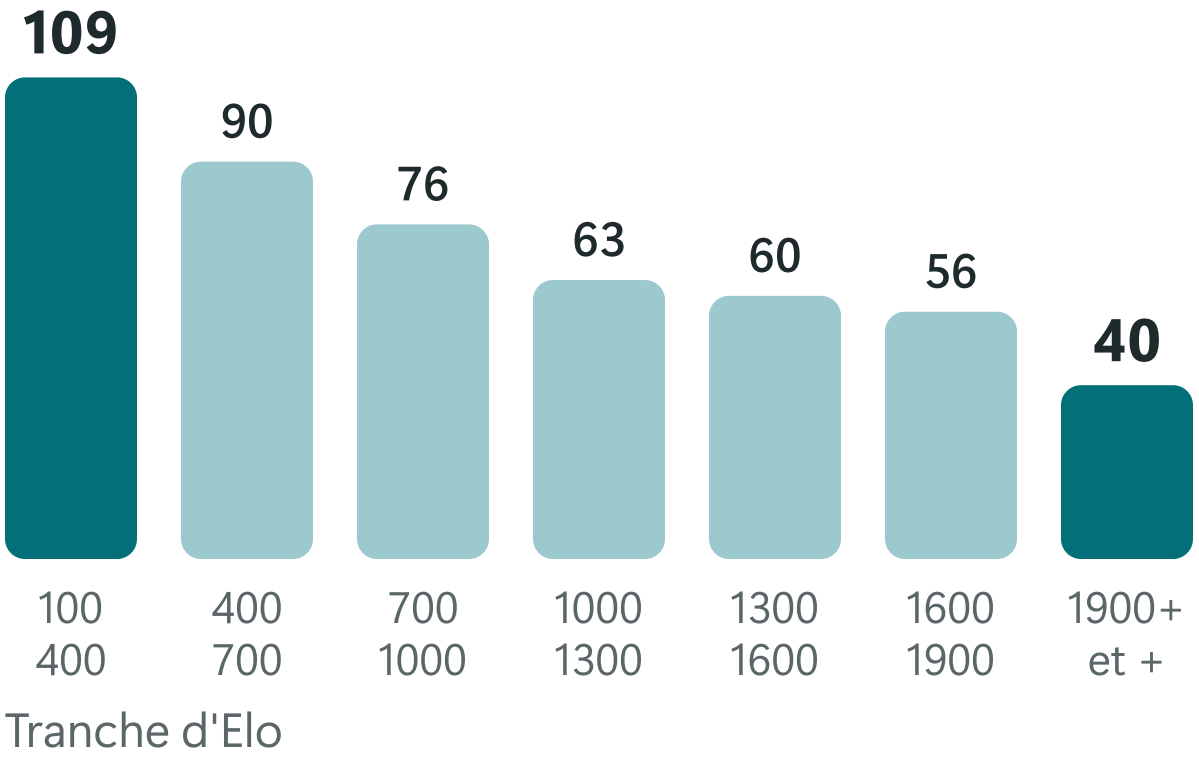
vraies parties rapides

856 joueurs · 12 mois

× 7 niveaux

de 100 à 1 900+

Stockfish mesure la qualité du jeu ; c'est au LLM d'en déduire l'Elo





Stockfish

109 → 40

centièmes de pion perdus par coup, des débutants aux plus de 1 900

1 pion = 100 centièmes. Perdre 100 en un coup, c'est comme offrir un pion à l'adversaire.

Il mesure les coups, pas l'Elo

Trois façons d'apprendre l'Elo à notre LLM, puis on lui demande de se justifier

Qwen3 **un nouvel employé** très cultivé, qui n'a jamais estimé un Elo

1. Prompt

des consignes et quelques exemples

2. RAG

des dossiers de cas similaires

3. Fine-tuning

une vraie formation

4. XAI

on lui demande de se justifier

Méthode 1 : on lui écrit des consignes et le résumé de la partie, il répond un Elo

CONSIGNE

Tu es un expert des échecs et du classement Elo de chess.com. Tu réponds uniquement par un nombre entier.

PARTIE, RÉSUMÉE PAR STOCKFISH

Pays du joueur : **États-Unis**

Couleur du joueur : **blancs**

Résultat : **victoire, échec et mat**

Nombre de coups : **55**

Gaffes · erreurs · imprécisions : **2 · 3 · 7**

ACPL : **58,3**

10 premiers coups : **1. g3 e5 2. Bg2 Nc6 3. Bxc6 ...**

Estime l'Elo rapide chess.com de ce joueur.

Qwen3 répond :

1 800

vrai Elo : **1 030**

Le pays : la seule ligne que l'on change pour mesurer le biais.

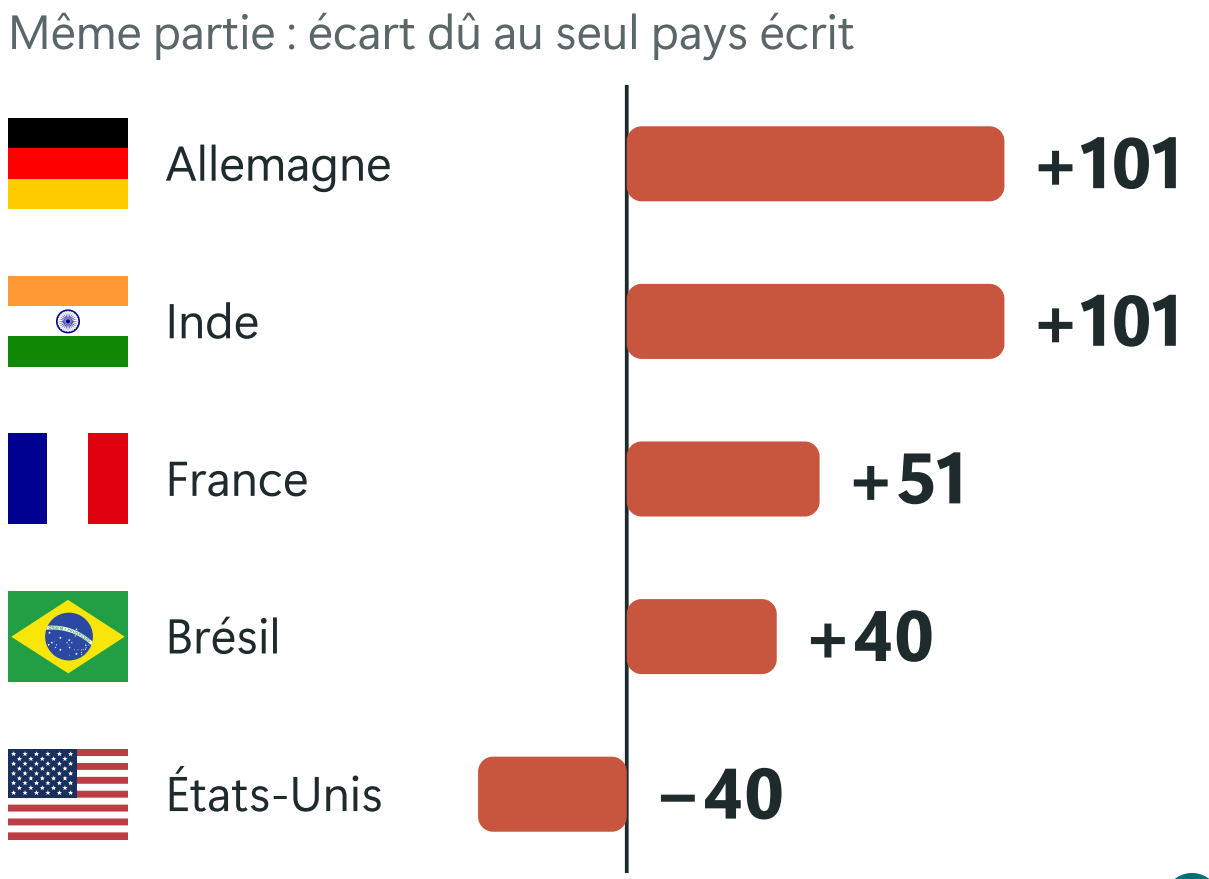
Few-shot : on ajoute avant 7 parties d'exemple avec leur vrai Elo.

Avec seulement des consignes, notre employé est à la fois ignorant et biaisé

1800

près d'une réponse sur deux

erreur moyenne : 644 points, pire qu'une réponse constante (530)



Qwen3 Méthode 1 · Prompt

Sept exemples mal choisis suffisent à créer un biais : le Brésil perd 243 points



−243 → −62

Brésil, par rapport à la France.

Mêmes 7 exemples, même ordre : on a seulement retiré leur pays.

⚠ Le biais peut venir de nous

Méthode 2 : on lui donne aussi les dossiers des 10 parties les plus proches

La partie à estimer

ACPL 58,3
2 gaffes · victoire

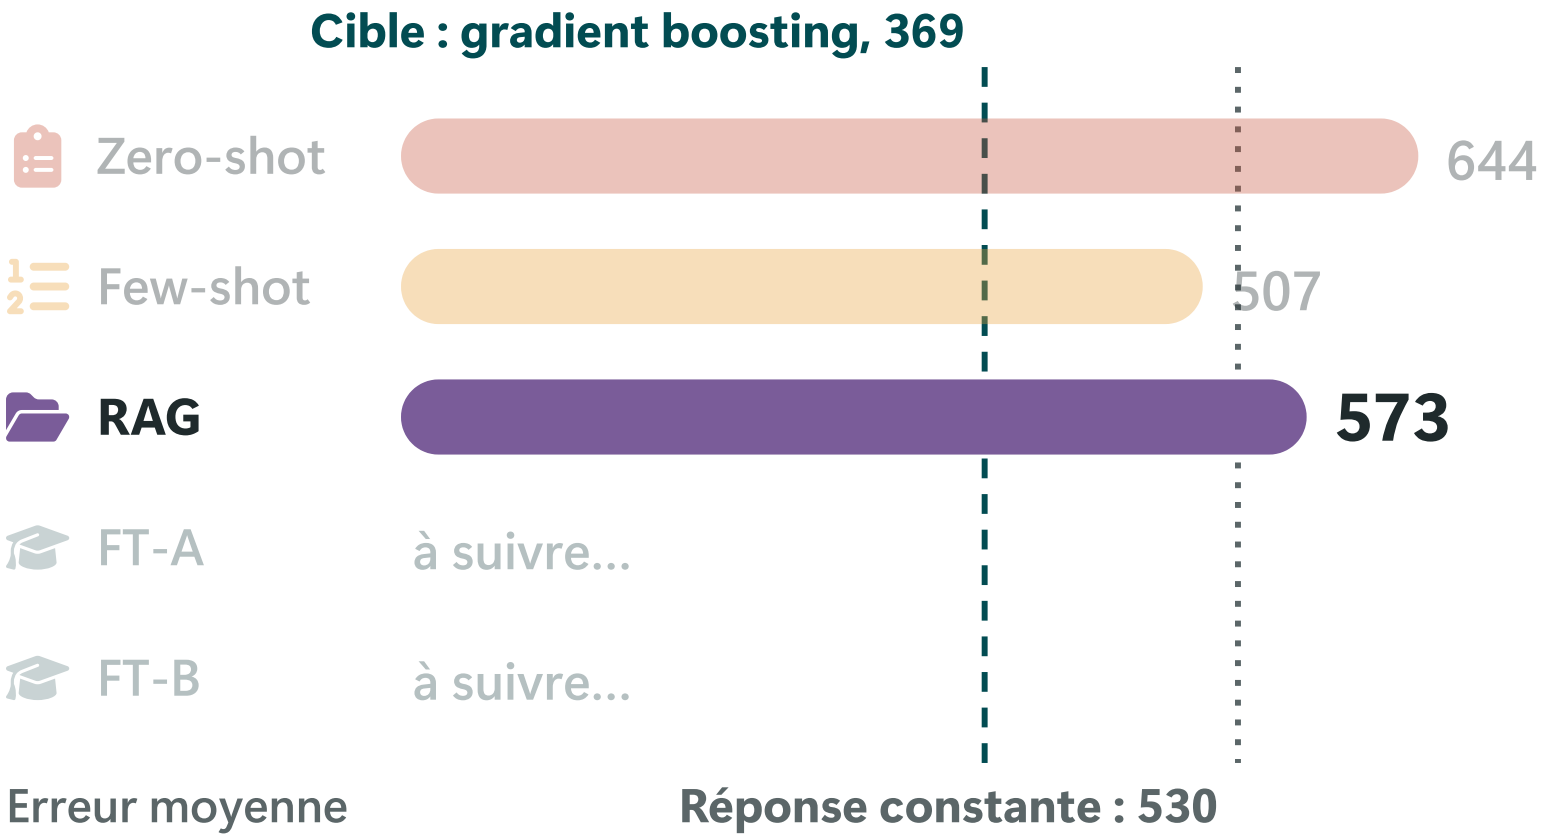
Les 10 parties les plus proches parmi nos 3 332 parties d'entraînement, avec leur vrai Elo

1 879	1 334	1 126	641	479
2 072	1 651	1 000	1 284	1 372

Qwen3 répond **1 450** vrai Elo : **1 030**

Les voisins sont choisis sur la **qualité du jeu** (ACPL, gaffes, coups, résultat), **jamais sur le pays**.

Avec des dossiers de cas similaires, il devient plus juste, mais pas plus utile



573

points d'erreur : plus qu'une réponse constante

Écart entre pays : **moins de 20 points**

Juste n'est pas utile

Méthode 3 : on l'entraîne vraiment, en lui montrant les parties et la bonne réponse

3 332 parties avec leur vrai Elo

- partie 1 → **152**
- partie 2 → **561**
- partie 3 → **2 337**

… lues 2 fois

Qwen3

on ajoute un **petit module** (LoRA) qui apprend ; le reste du modèle ne bouge pas

sur la même partie

1 017

vrai Elo : **1 030**

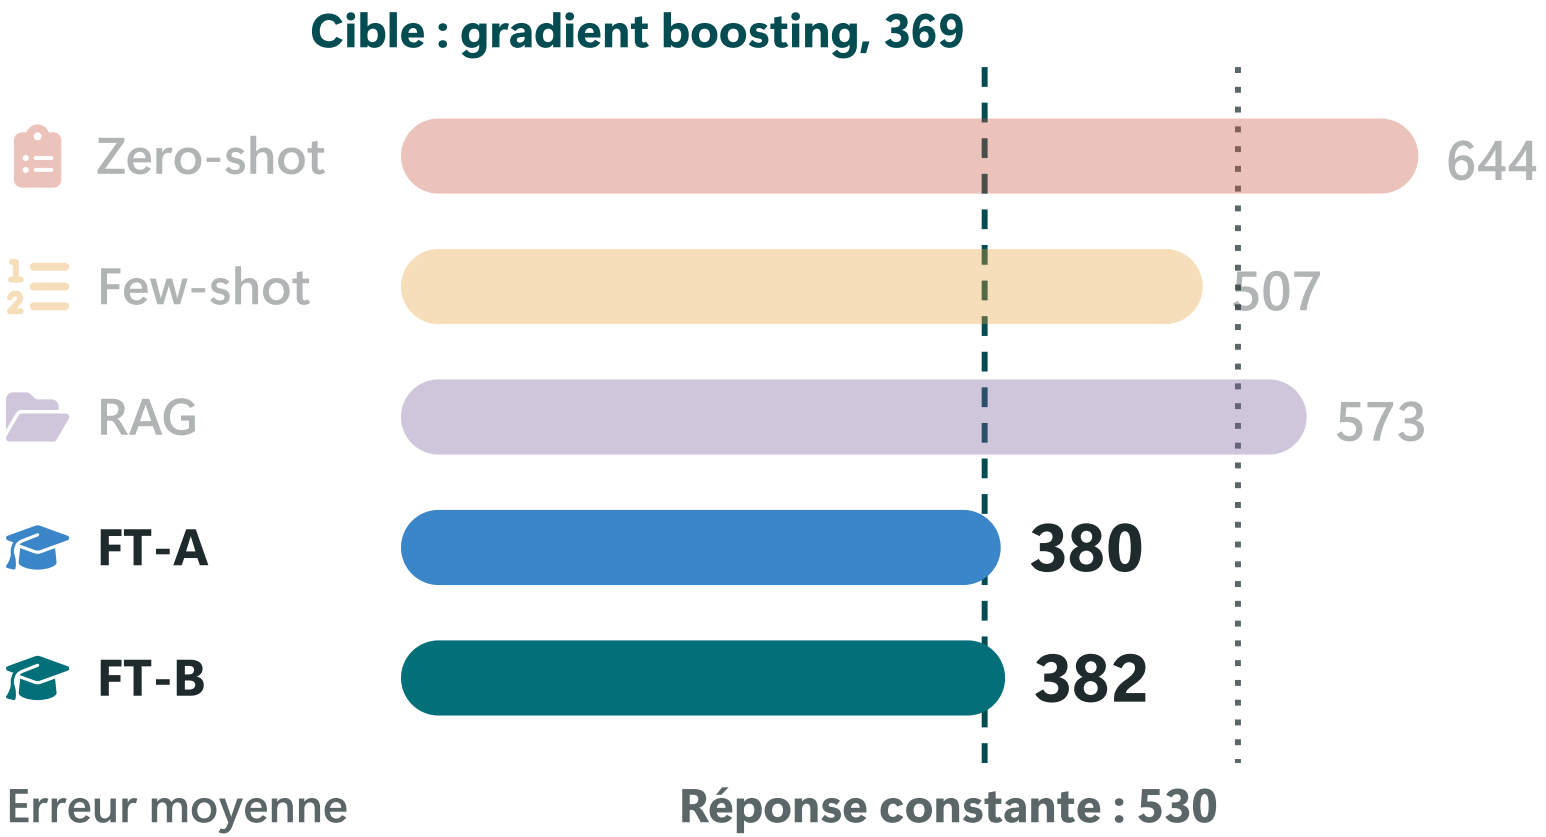
FT-A voit le **vrai pays** du joueur



FT-B voit un **pays tiré au hasard**



Une fois vraiment formé, il devient enfin compétent : aussi précis qu'un modèle classique



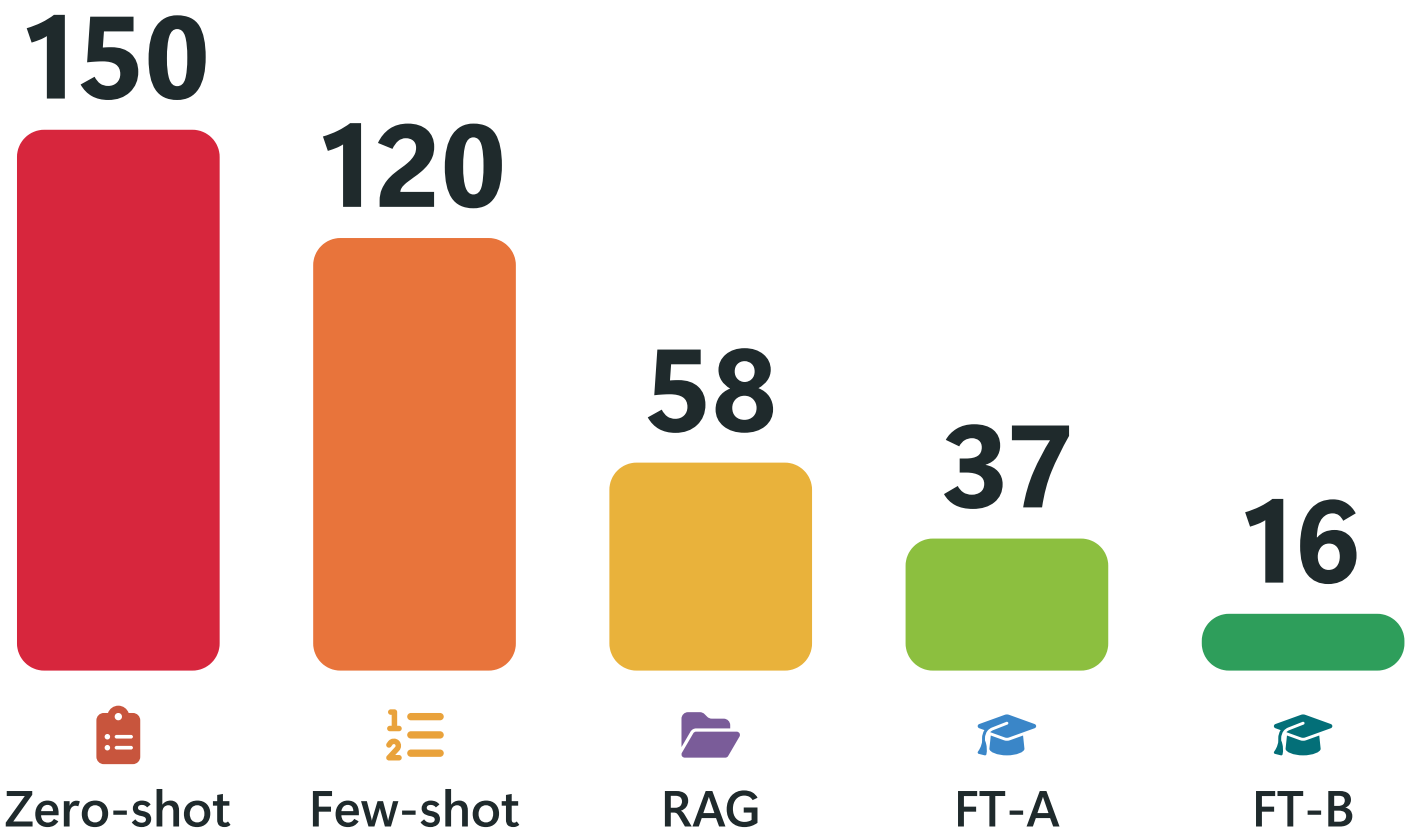
380

points d'erreur, contre 644 au départ

≈ la cible : 369

sur les 437 parties de test

L'effet du pays fond : de 150 à 16 points



150 → 16

points d'écart entre pays, pour une même partie

Le pays change la prédiction : **78 %** → **10 %** des parties

FT-B : notre modèle retenu

Notre modèle ne regarde plus le pays, mais le jeu

On cache une information à la fois, et on mesure de combien sa réponse change (SHAP). Classement sur 12.

Modèle de base

1	Victoire ou défaite	36 %
2	**Pays**	**15,5 %**
3	Fin de partie	13 %
4	Ouverture	10 %

Notre modèle (FT-B)

1	Ouverture	32 %
2	ACPL (pertes par coup)	29 %
3	Premiers coups	23 %
…		
11	**Pays**	**0,2 %**

15,5 % → 0,2 % part du pays dans la décision

SHAP mesure, LIME confirme

Et sur nous ? Nos modèles face à nos propres parties

Nous sommes fans d'échecs : après les 437 parties de test, le vrai test, c'était **nos propres parties**.

Thibault

959 Elo

10 parties

Maël

492 Elo

10 parties

Hugo

877 Elo

5 parties

Paul Carrère

1 494 Elo

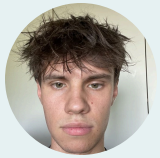
10 parties

notre ami de classe l'an dernier, qui nous a initiés aux échecs

Nos dernières parties rapides, analysées par Stockfish comme le dataset, avec le pays « France ».

Le modèle de base classe Paul dernier ; le nôtre, premier

Elo moyen sur nos 10 dernières parties rapides (5 pour Hugo) · règle de 100 à 2 000



Thibault

Réel 959 · Notre IA 1 179 · Base 1 630



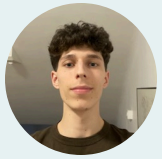
Maël

Réel 492 · Notre IA 1 007 · Base 1 700



Hugo

Réel 877 · Notre IA 837 · Base 1 680



Paul

Réel 1 494 · Base 1 570 · Notre IA 1 737

La partie du début : Maël, 490 · Base 1 400 · Notre IA 371

Erreur par partie : 694 → 423

Et si Paul se présentait comme américain ? 95 points de moins pour le modèle de base, rien pour le nôtre

Paul vit aux États-Unis depuis cette année. Test : ses 10 parties, présentées deux fois. **Seul le pays écrit change ; son jeu est identique.**



Trait gris : son vrai Elo, 1 494

Conclusion

Un biais se mesure et se réduit, mais un modèle juste n'est pas forcément un bon modèle

Le **dataset équilibré** et le **fine-tuning** ont le plus réduit le biais

Le biais peut **venir de nous** : 7 exemples ont suffi

Un modèle **équitable** n'est pas forcément **utile**

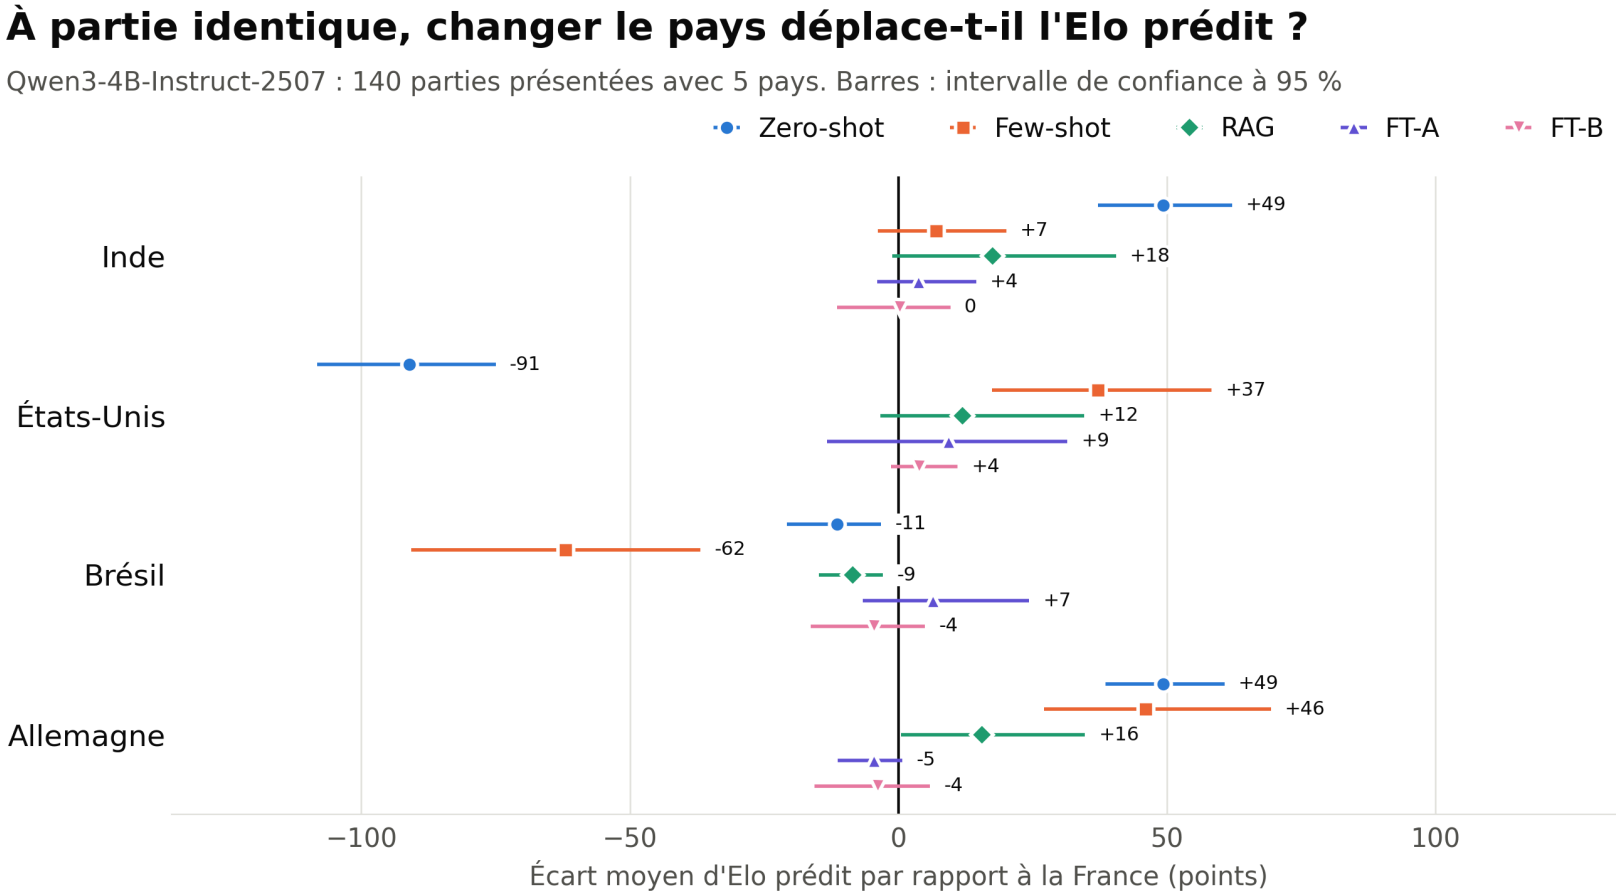
Nos limites

- Réponses concentrées sur 23 valeurs (1677, 1777, 101...)
- FT-B ne fait pas significativement mieux que FT-A
- Petits échantillons : 140 parties pour le biais, 12 pour l'XAI

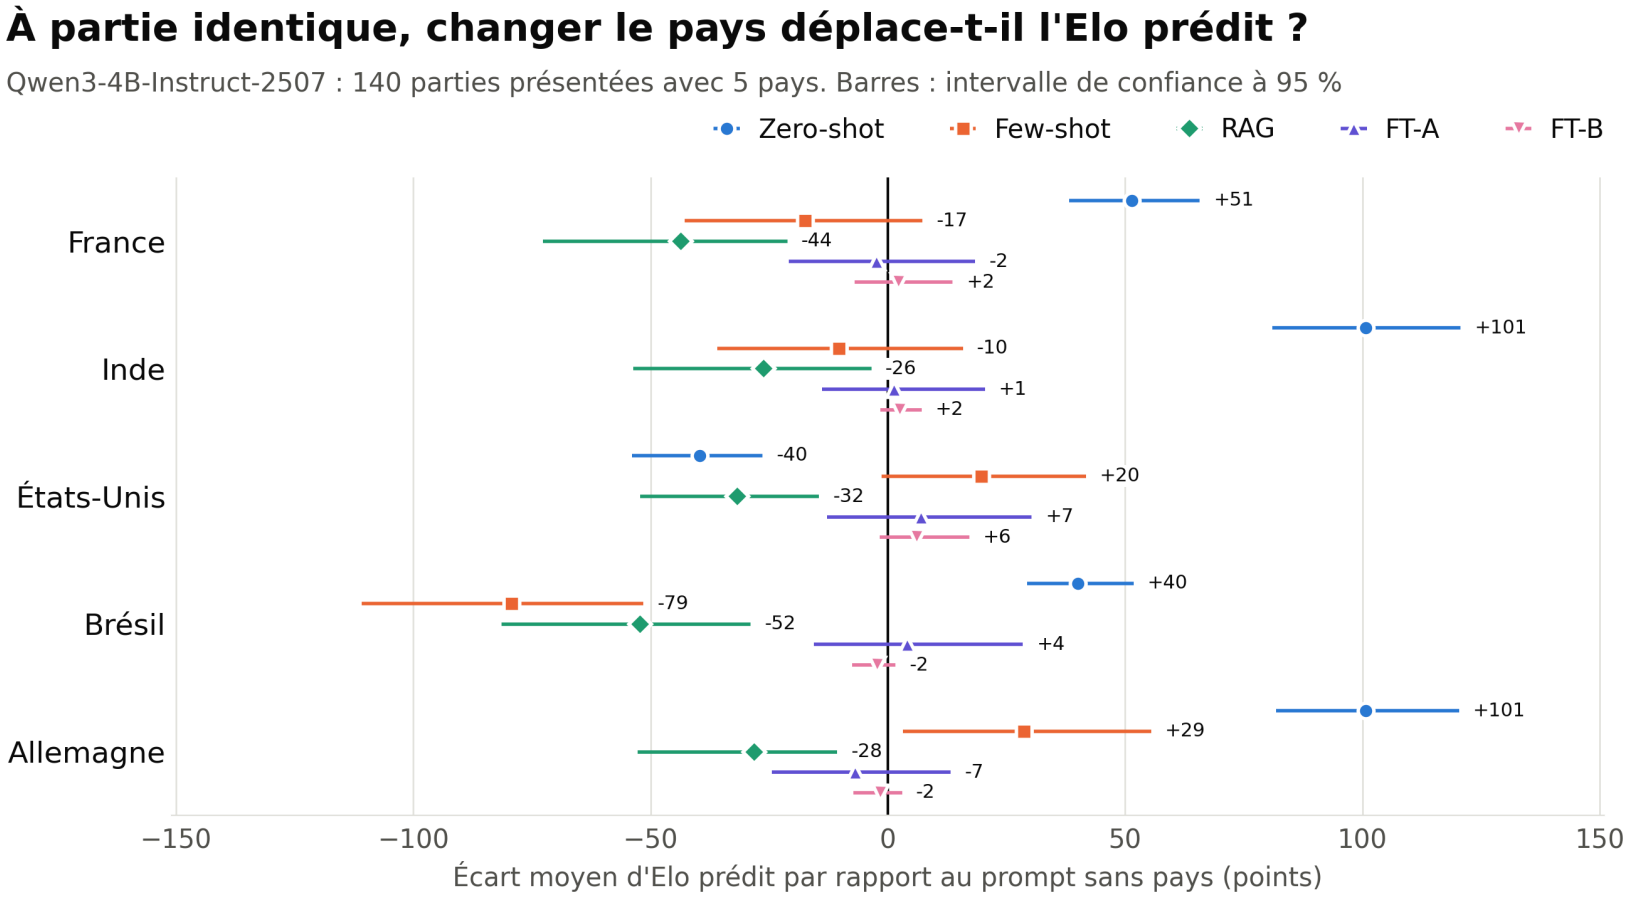
Annexes

Figures détaillées pour les questions

Écart de chaque pays avec la France, pour les 5 méthodes



Écart de chaque pays avec le prompt sans pays



Pourquoi SHAP est notre mesure principale, et LIME le contrôle

Additivité exacte

Valeur de base + contributions = prédiction, exactement. LIME n'est qu'une approximation locale.

Fiable sur un cas connu

Modèle simulé où le pays n'a aucun effet : SHAP lui donne 0 %, LIME environ 5 %.

Pas deux preuves indépendantes

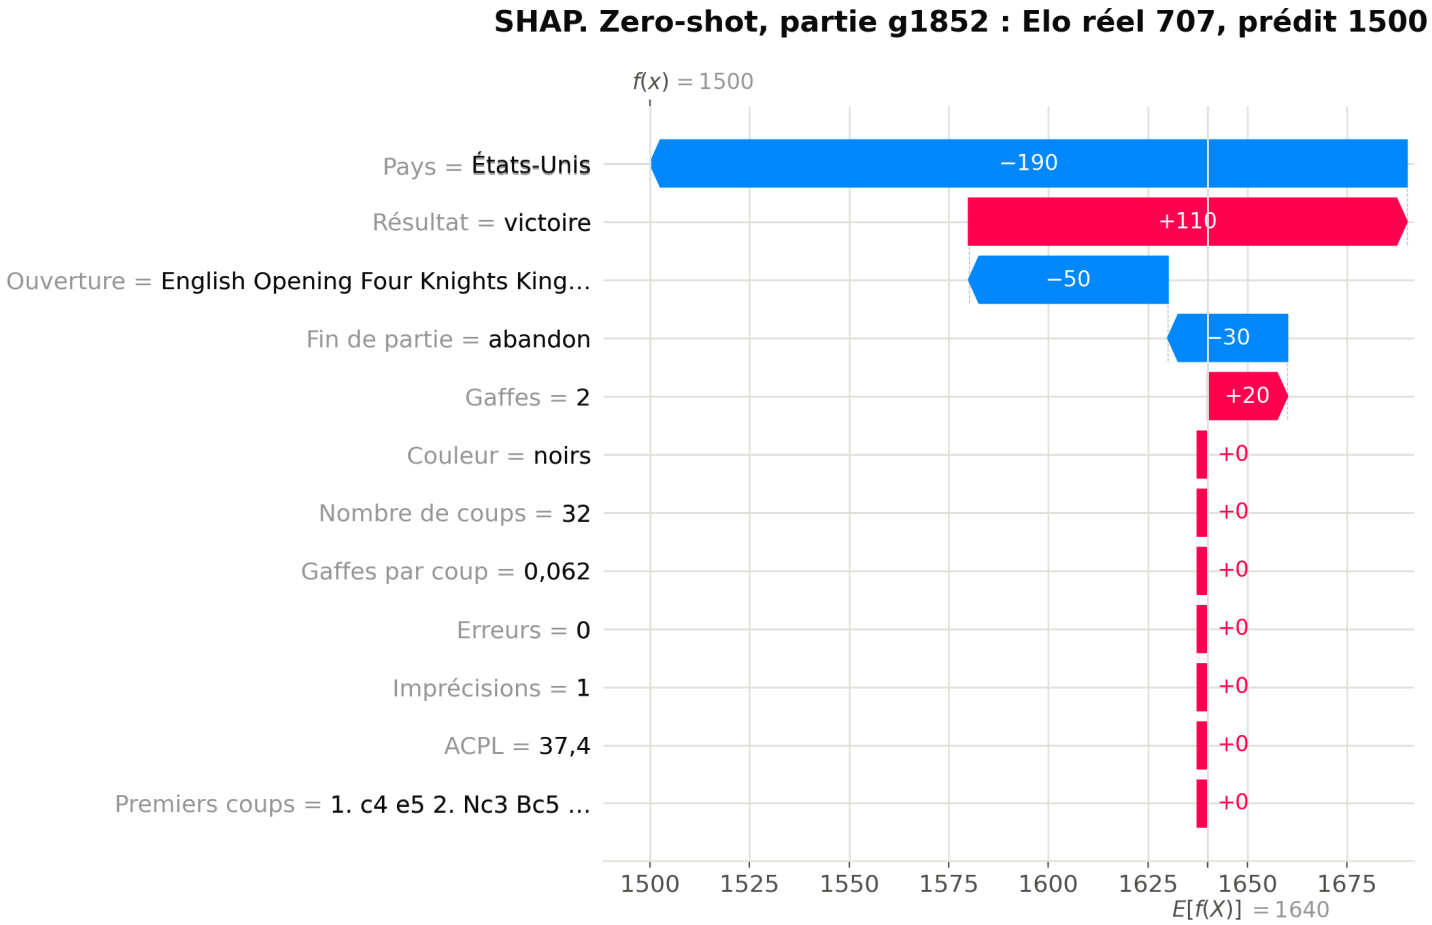
LIME réutilise les prédictions de SHAP : leur accord confirme, sans prouver deux fois.

Limite commune

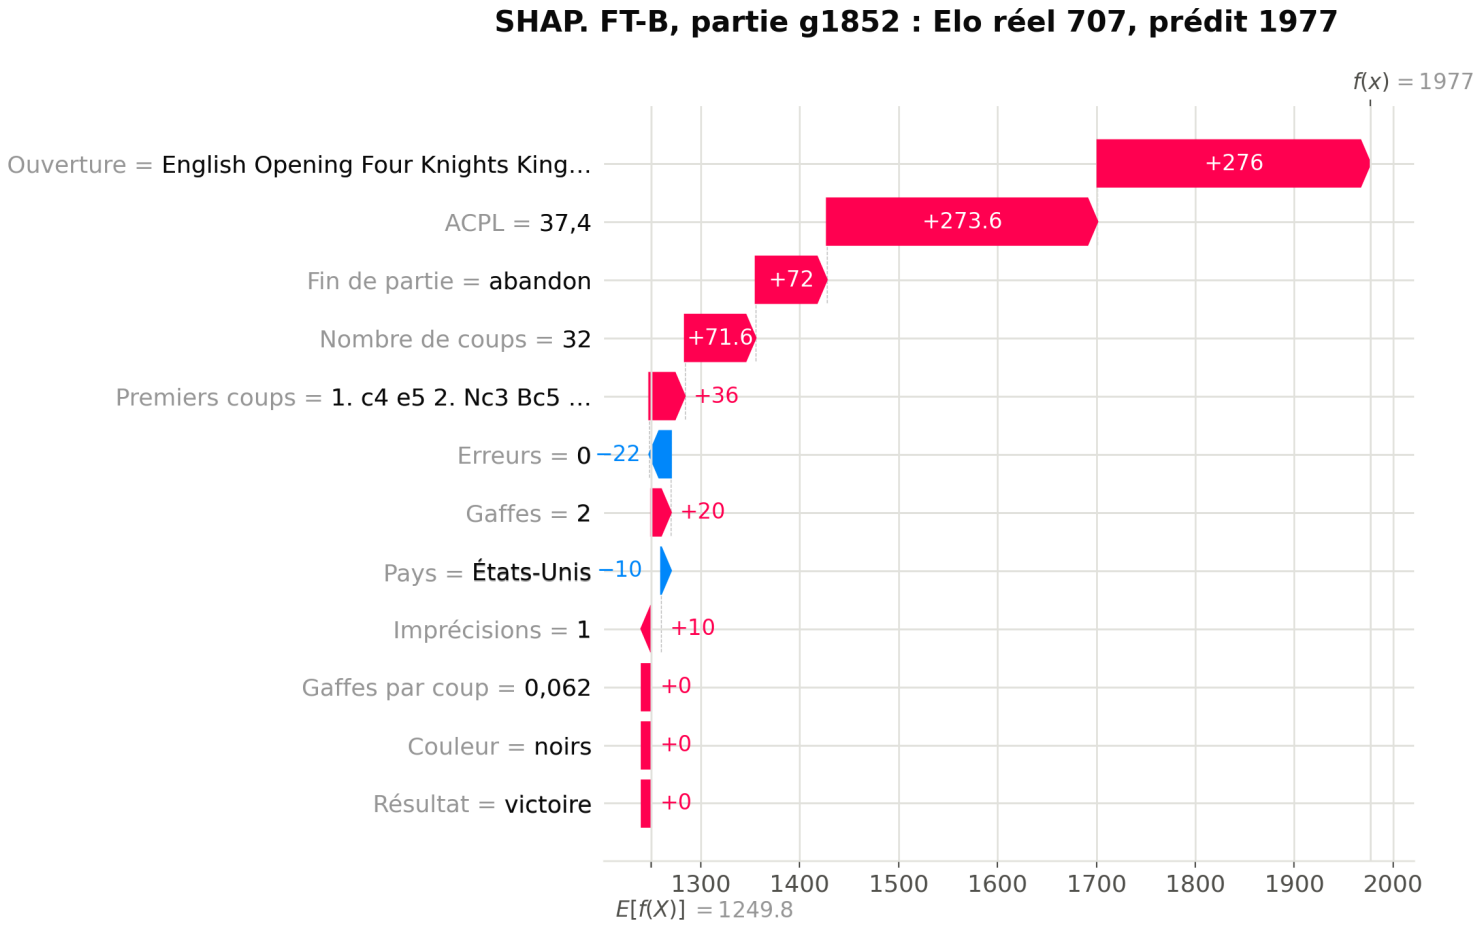
Masquer une variable mélange deux parties : certains prompts deviennent incohérents.

Part du pays selon LIME : 8,8 % (base), 7,0 % (FT-A), 5,8 % (FT-B), même ordre que SHAP.

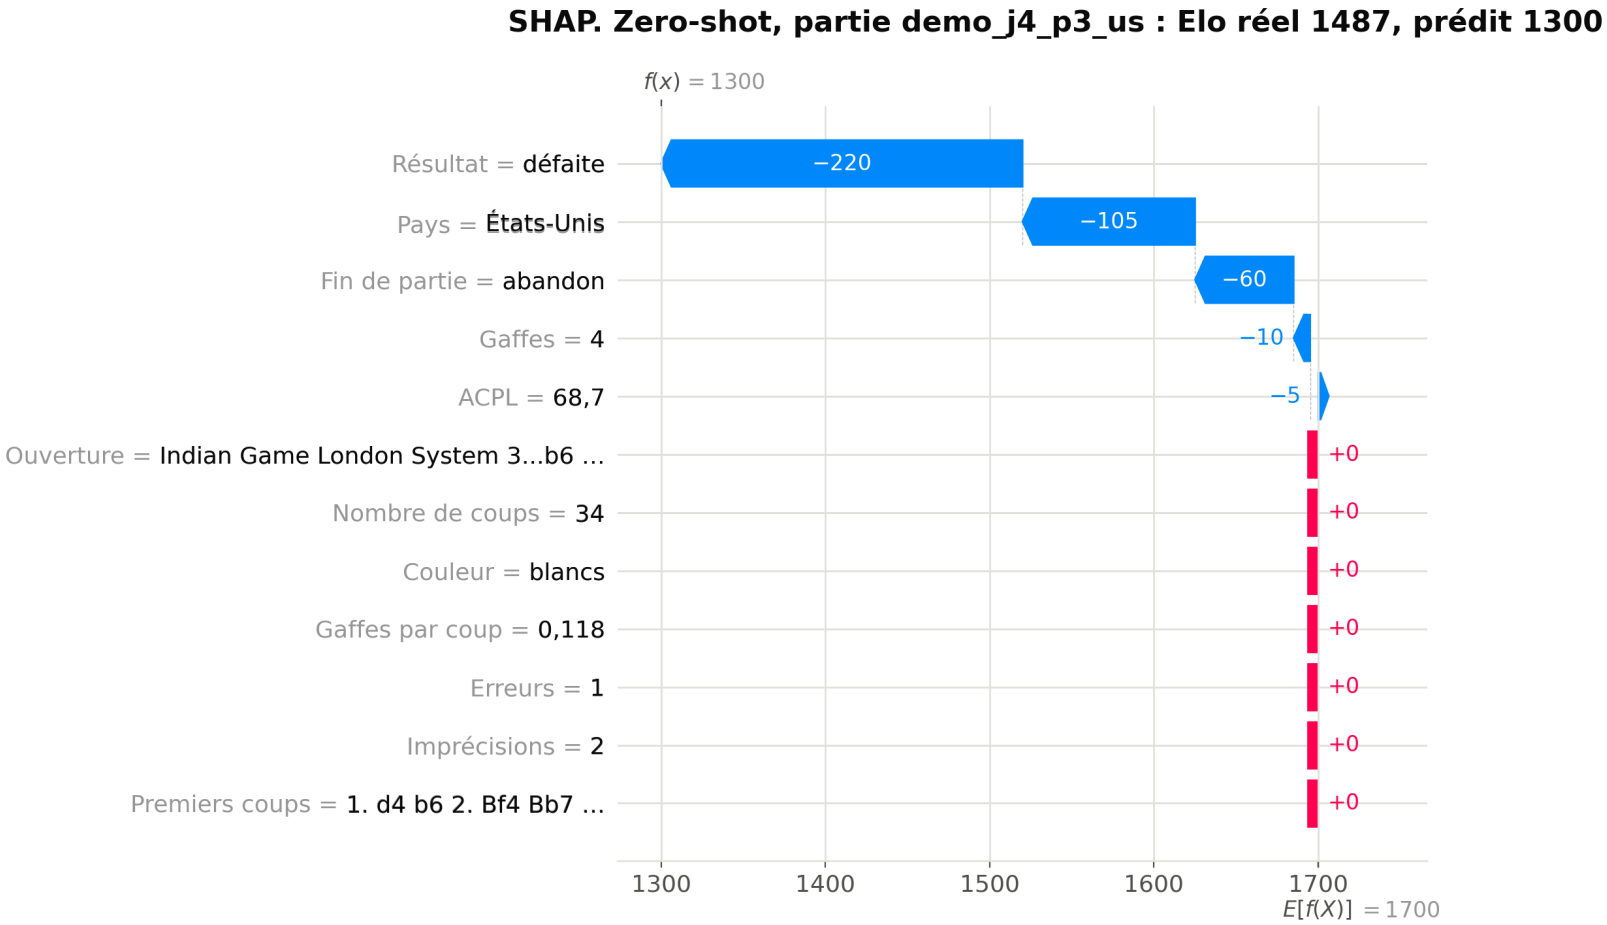
Partie g1852 (États-Unis, 707 Elo) : le pays retire 190 points au modèle de base



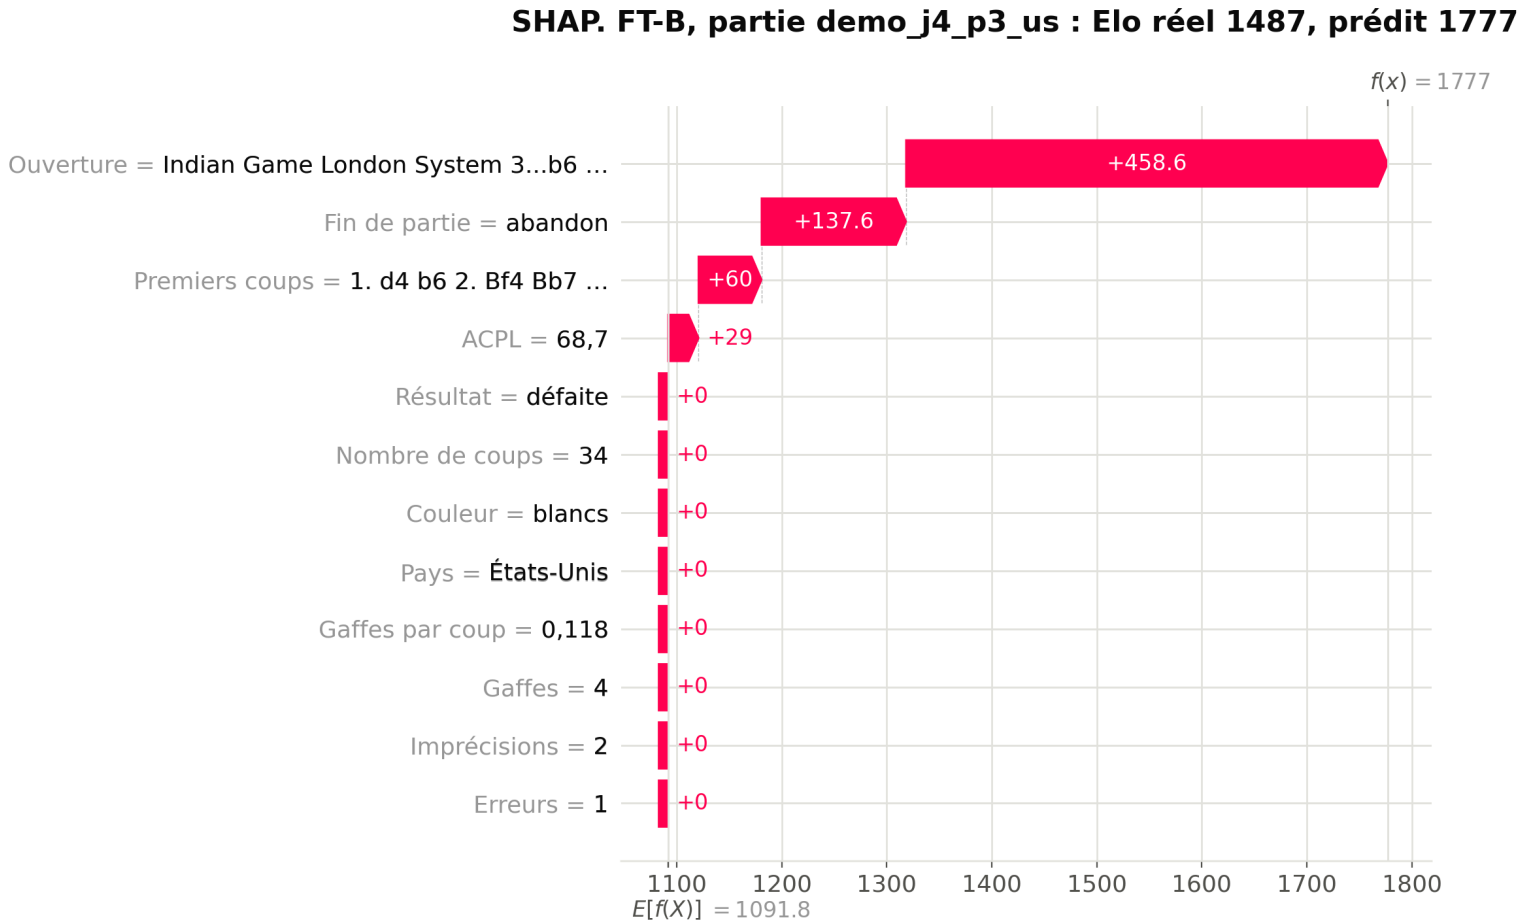
Même partie avec FT-B : le pays ne pèse plus que −10 points



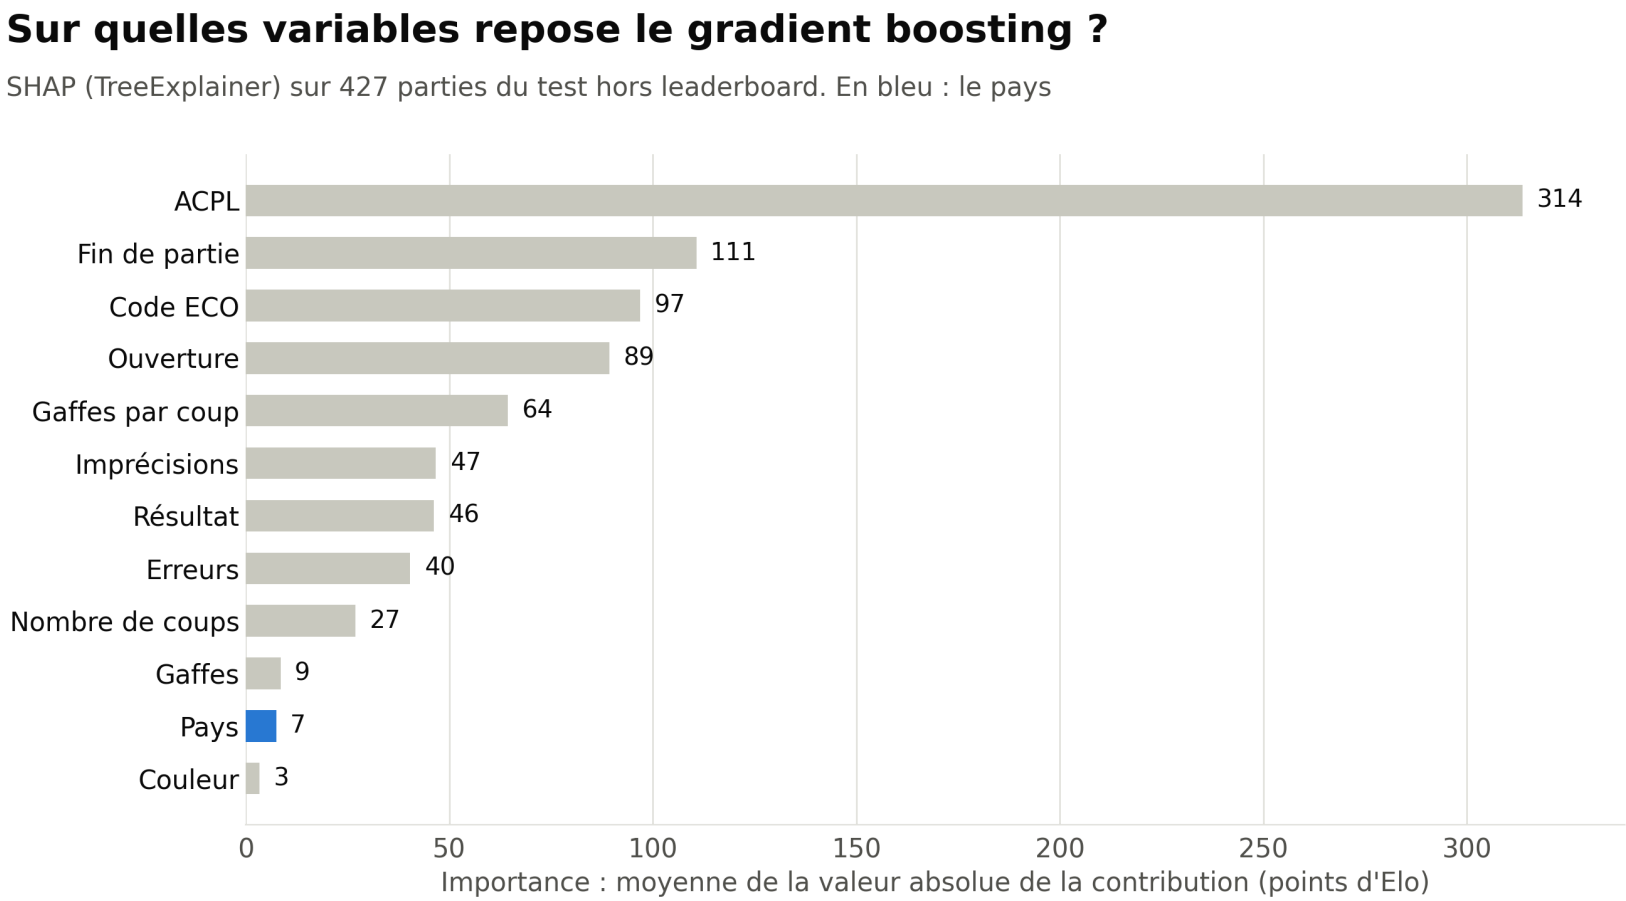
Partie 3 de Paul, version « États-Unis » : −105 points pour le modèle de base



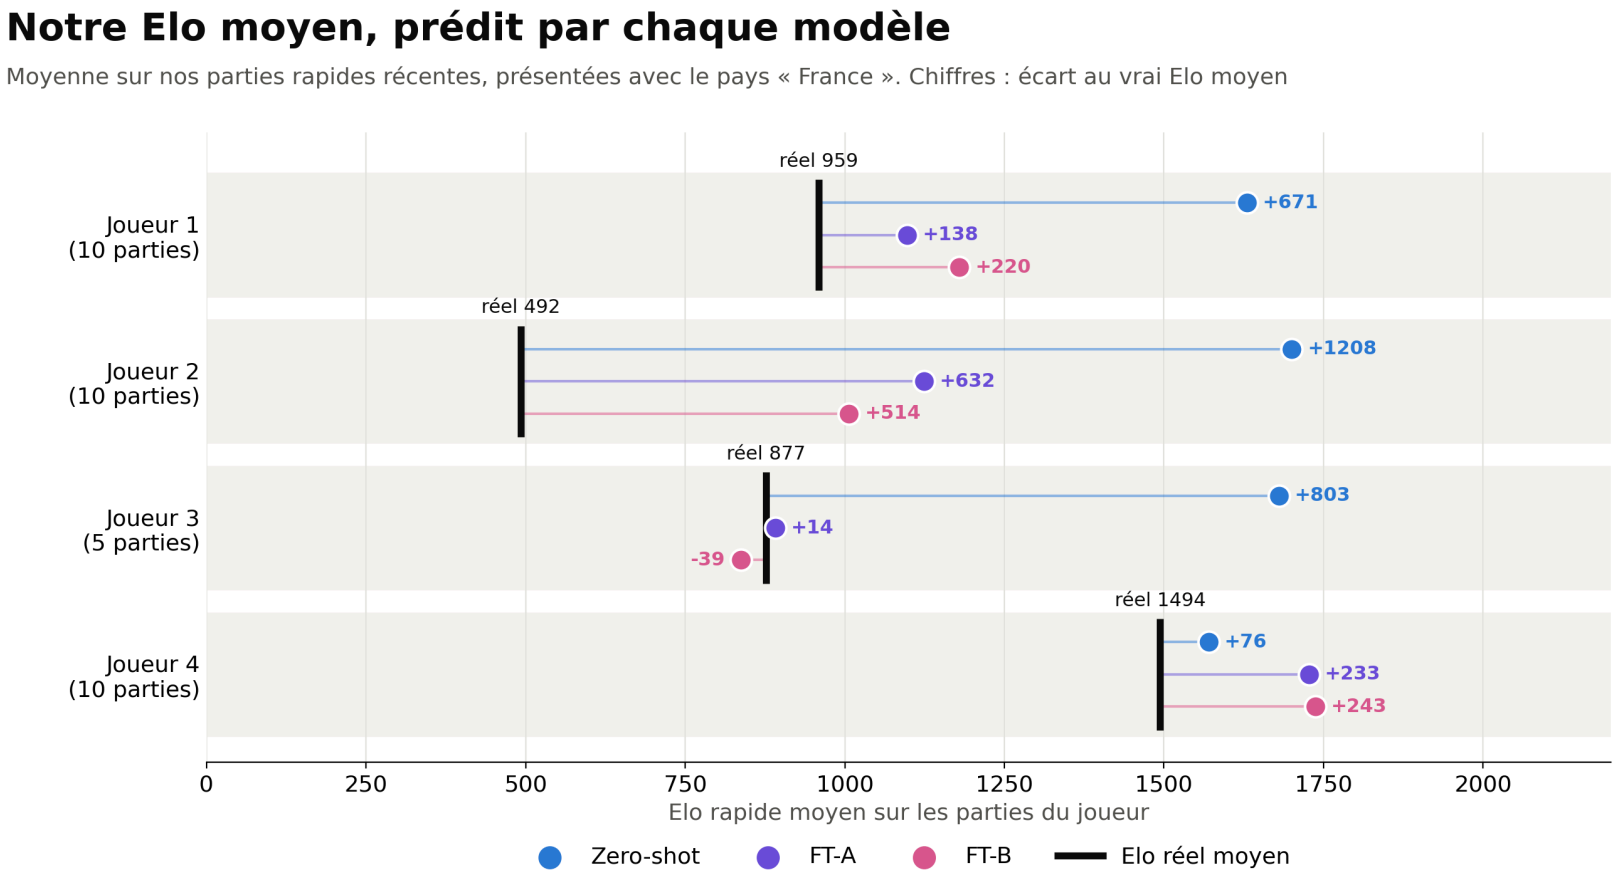
Même partie de Paul avec FT-B : le pays ne pèse rien



Le gradient boosting n'accorde que 0,9 % au pays, et 37 % à l'ACPL



Démo complète avec FT-A, sur nos 10 dernières parties rapides (5 pour Hugo)



Le benchmark complet : précision et indépendance au pays

Approche	Erreur	R^2	Bonne tranche	Écart pays	Pays (SHAP)
Constante	530	0,00	15 %	0	—
Régression linéaire	377	0,42	28 %	—	—
Gradient boosting	369	0,44	26 %	—	0,9 %
Médiane des voisins	453	0,18	21 %	0	—
Zero-shot	644	−0,57	14 %	150	15,5 %
Few-shot	507	0,06	16 %	120	—
RAG	573	−0,31	16 %	58	—
FT-A	380	0,39	28 %	37	1,0 %
FT-B (retenu)	**382**	**0,38**	**29 %**	**16**	**0,2 %**